고속도로 위험이벤트 예측을 위한 통합 데이터 기반 머신러닝 모델 개발

VDS·기상·도로구조·시설물 데이터를 활용한 위험요인 분석

6조

박선우

정채환

최윤호

임선영



목차 Summary

01 **연구개요**

연구배경 | 연구목적 | 연구 Framework

02 **데이터 구축 및 파생변수 생성**

데이터 수집 | 데이터셋 구축 | 초기 EDA | 전처리 | 파생 변수 생성

03 **가설 확인 및 EDA**

가설 설정 | EDA | 가설검정

04 **머신러닝 모델 개발**

변수선정 | 모델 비교 | 하이퍼 파라미터 튜닝 | SHAP 분석

05 **연구 기여도 및 시사점**

통합모델 효과 검증 | 연구 기여도 | 결론 및 시사점

06 **마무리**

한계점 | 참고문헌 | Q&A

1-1. 연구배경

Research Background

기존 교통류 중심 위험분석의 한계를 극복하기 위해
교통류·기상·도로구조·시설물 데이터를 통합한 위험이벤트 예측모델을 구축하고자 함

기존 연구

01 사고 발생 후 원인 분석

사고 발생 이후 원인요인 규명 중심

성제민·윤병조 (2024), XGBoost를 활용한 첨두·비첨두시간 사고 심각도 영향요인 분석

02 교통류 중심 분석

속도·교통량·점유율 중심 분석

정은비·오철 (2011), 속도를 이용한 고속도로 구간 사고율 예측 모형

03 사고 데이터 중심 연구

사고 발생 여부 직접 예측

Chen et al. (2025), Traffic Accident Severity Prediction Based on an Enhanced XGBoost Model

04 위험요인 설명 중심

통계적 관계 분석 위주

최강록·박훈태·맹기영 (2025), 도로 기하구조의 연속성이 교통사고 심각도에 미치는 영향

본 연구

01 위험이벤트 사전 예측

사고 이전 위험상황 조기 탐지

02 교통류·기상·도로구조·시설물 통합 분석

교통류·기상·시설물·도로구조 결합

03 Hard Braking 기반 위험지표 활용

사고+급감속 통합 위험이벤트 정의

04 머신러닝 기반 위험예측 모델 구축

최종 LightGBM 기반 위험예측 수행

1-2. 연구 목적

고속도로 위험이벤트 발생에 영향을 주는
핵심 요인은 무엇인가?

위험요인 규명

Identify Key Risk Factors

위험이벤트 발생에 영향을 미치는
주요 요인을 식별

예측모델 구축

Develop a
Prediction Model

머신러닝 기반
위험이벤트 예측모델 개발

**통합 데이터
효과 검증**

Validate the Effect of
Integrated Data

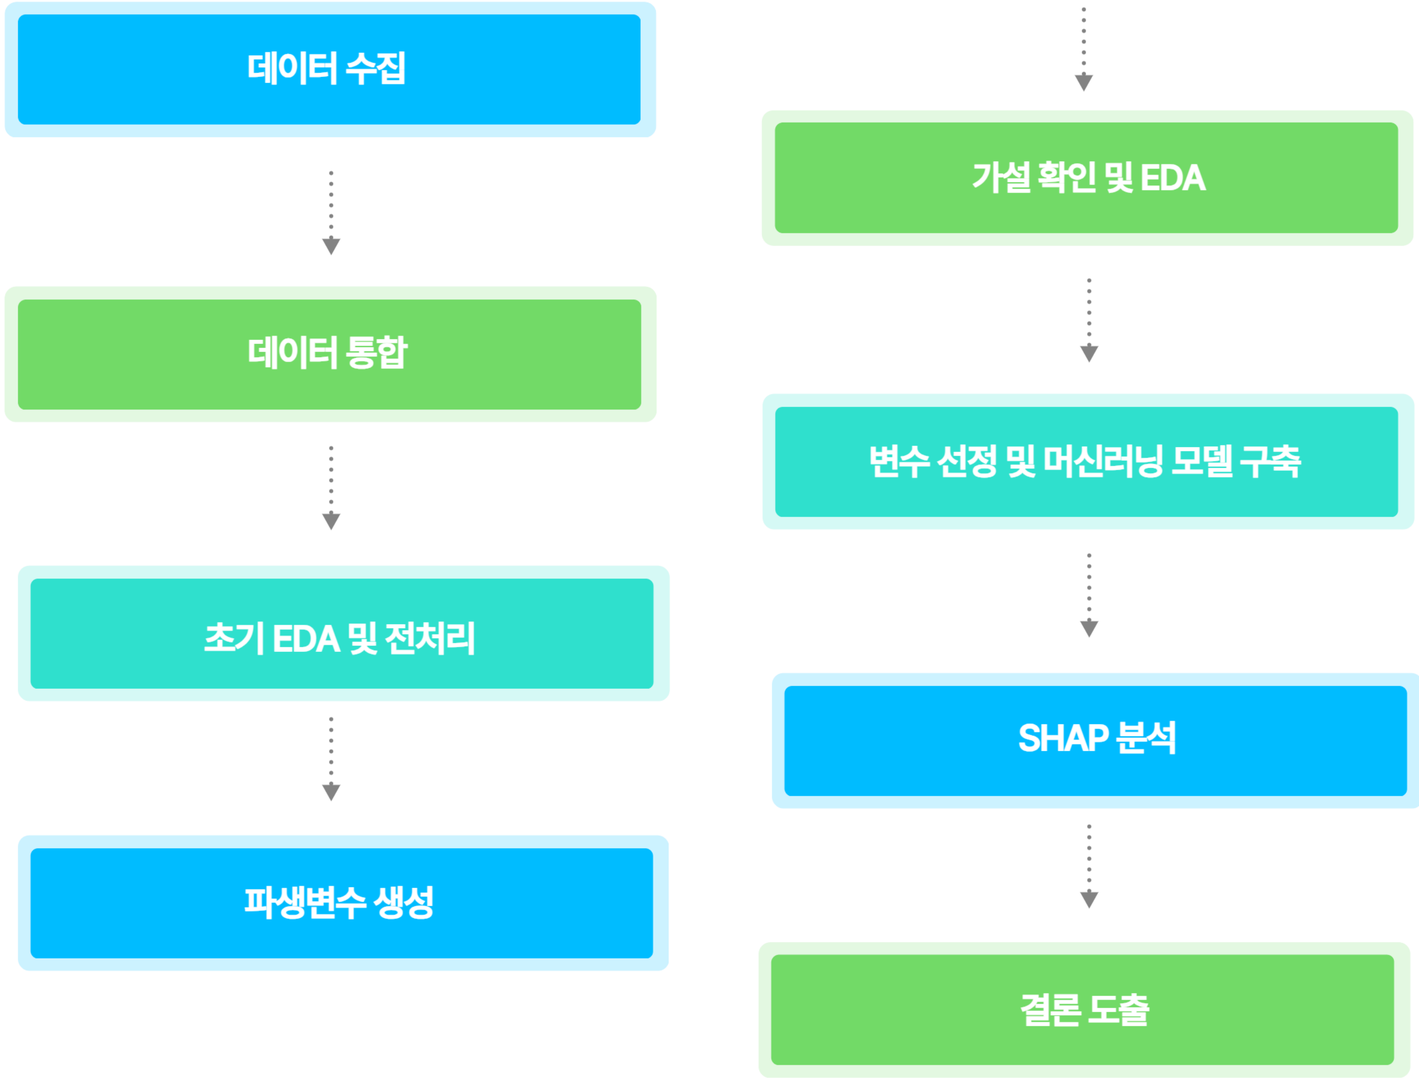
교통류 외 변수들의
추가 효과 검증

다양한 데이터를 통합하여 위험이벤트 발생 메커니즘을 규명하고 예측 가능한 모델을 구축하고자 함

1-3. 연구 Framework

Research Framework

- 데이터 통합부터 위험요인 분석, 머신러닝 예측 및 모델 해석까지의 전체 연구 절차를 수행



2-1. 데이터 수집

Data Collection

- 다양한 데이터 소스를 활용하여 통합 분석 기반 구축
- 기존 교통류 중심 연구를 확장
- 위험이벤트를 다각적으로 설명할 수 있는 데이터 확보

교통류, 기상, 도로구조, 시설물 정보를 통합하여 위험이벤트 발생에 영향을 미치는 다양한 요인 분석

데이터	시공간 범위	주요 변수	활용 목적
VDS 교통류 데이터	경부선 구서IC - 양재IC 22.01.01 - 22.04.30	Speed, Volume, Occupancy	교통류 상태 분석 및 정체 특성 파악
도로선형(SHP) 데이터	경부선 구서IC - 양재IC	곡률, 방위각, 방향변화량	도로구조 및 선형 특성 분석
시설물 데이터	경부선 구서IC - 양재IC	IC, JC, TG, 교량, 터널, 차로수	시설물 인접 효과 및 공간적 특성 분석
사고 데이터	경부선 구서IC - 양재IC 22.01.01 - 22.04.30	사고건수, 사고위치	보조 EDA 및 결과 검증
ASOS 기상 데이터	경부선 구서IC - 양재IC 22.01.01 - 22.04.30	강수량, 기온, 습도	기상 조건 영향 분석

2-2.데이터 구축

Data Integration

- 다양한 데이터 소스를 통합하여 데이터마트 구축
- 약 1,170만 건의 대규모 분석 데이터 확보
- 위험이벤트 설명을 위한 통합 분석 기반 마련

데이터 조인 과정

- VDS 교통류 데이터
- ASOS 기상 데이터
- 도로선형(SHP) 데이터
- 시설물 데이터
- 공간·시간 기준 데이터 조인
- 최종 데이터셋 구축
- 사고데이터 추가 (보조 EDA용)

분석구간	분석기간	관측치 수	변수 수	위험 이벤트 수	위험 이벤트율
경부고속도로 S방향	2022.01 ~ 2022.04	11,704,666건	100+개	86,354건	0.7378%

총 1,170만 건 이상 규모의 통합 데이터셋을 구축하여 위험이벤트 예측 분석에 활용

2-3. 초기 EDA

Initial EDA Results

초기 EDA 결과, 일부 데이터에서 이상치·결측치·중복치가 확인되었으며
모델링 전 데이터 품질 개선이 필요한 것으로 나타남

데이터	결측치	이상치	중복치
VDS	X	O	X
ASOS	O	X	X
도로기하구조	X	X	X
사고차량	O	X	O
시설물	X	X	X

주요 발견사항

01.

VDS

speed < 0

vol < 0

occ < 0

occ > 100

speed > 150

물리적으로 불가능한 값

02.

ASOS

강수량 결측 존재

적설 결측 존재

습도 결측 (9건)

기온 결측 (1건)

일부 결측 존재

03.

사고차량

결측치 존재

중복 64건

결측, 중복 존재

2-4. 데이터 전처리

Data Preprocessing

데이터 특성에 적합한 전처리 기법을 적용하여 데이터 품질을 개선하고
모델 학습에 적합한 최종 데이터셋을 구축



VDS

도메인 기반 이상치 제거



ASOS

강수량·적설 → 0 대체
습도 → 중앙값 대체
기온 → 선형보간



사고차량

결측값 → 미상 처리
중복치 → 제거

전처리 원칙

구조적 결측 → 0 대체
MCAR 결측 → 중앙값 대체
시계열 결측 → 선형보간
물리적 이상치 → 제거

2-5. 변수 생성

Feature Engineering

- speed
- vol
- occ
- rainfall
- curvature
- IC,JC,TG

교통류 입력 변수

- SSD_5 / SSD_15 — 연속형 - 단/장기 공간적 속도차 반영
- speed_cv — 연속형 - 속도 변동성 반영
- flow_density — 연속형 - 교통밀도 반영
- occ_speed_ratio — 연속형 - 정체 수준 반영

공간·시설물 입력 변수

- facility_flag_500m — 이진형 - 시설물 인접 여부 반영
- ic_near_500M — 이진형 - IC 인접 여부 반영

융합 변수

- curve_vol_density — 연속형 - 굴곡도와 교통밀도 반영
- tunnel_occ — 연속형 - 터널 구간 정체 수준 반영

종속변수

- risk_score= crash_count+0.3 × hardbraking_count
- 'event_binary =crash > 0' or 'hardbraking > 0'

교통류, 시간정보, 도로환경 및 복합 위험요인을 반영한 총 36개의 신규 변수

2. 데이터 구축 및 파생 변수생성

번호	변수명	한글 해석	변수 유형
1	TSD_5	5분 시간적 속도차	연속형
2	TSD_10	10분 시간적 속도차	연속형
3	TSD_15	15분 시간적 속도차	연속형
4	SSD_5	5분 공간적 속도차	연속형
5	SSD_10	10분 공간적 속도차	연속형
6	SSD_15	15분 공간적 속도차	연속형
7	TSSD_5	5분 시공간 속도차	연속형
8	TSSD_10	10분 시공간 속도차	연속형
9	TSSD_15	15분 시공간 속도차	연속형
10	hour	시간대	범주형
11	month	월	범주형
12	dayofweek	요일	범주형
13	is_weekend	주말 여부	이진형
14	is_holiday	공휴일 여부	이진형
15	peak_flag	첨두시간 여부	이진형
16	night_flag	야간 여부	이진형
17	is_peak_weekday	평일 첨두 여부	이진형
18	speed_cv	속도 변동계수	연속형

번호	변수명	한글해석	변수유형
19	speed_drop	속도 감소량	연속형
20	speed_drop_ratio	속도 감소율	연속형
21	flow_density	교통류 밀도 지표	연속형
22	lane_vol_ratio	차로당 교통량 비율	연속형
23	occ_speed_ratio	점유율-속도 비율	연속형
24	hardbraking_rate	급감속 발생률	연속형
25	rolling_event_30m	최근 30분 위험이벤트 누적치	연속형
26	curve_speed_risk	곡선구간 속도감소 위험지수	연속형
27	curve_vol_density	곡선구간 밀도 위험지수	연속형
28	curve_TSD	곡선구간 교통류 불안정성 지수	연속형
29	curve_wet_risk	곡선구간 우천 위험지수	연속형
30	facility_speed_drop	시설물 인근 속도감소 위험지수	연속형
31	tunnel_occ	터널구간 점유율 지수	연속형
32	bridge_occ	교량구간 점유율 지수	연속형
33	night_curve_risk	야간 곡선구간 위험지수	연속형
34	rain_curve_risk	강우-곡선 복합 위험지수	연속형
35	weather_risk	기상 위험지수	연속형
36	congestion_curve_risk	혼잡-곡선 복합 위험지수	연속형

02-6. 데이터 특성

Data Characteristics

위험이벤트 비율이 1% 미만으로 매우 낮기 때문에,
단순 정확도보다는 위험이벤트를 놓치지 않는 Recall 중심의 평가가 중요하다고 판단

01.
심한 클래스 불균형

위험이벤트율 0.7378%
정상 데이터가 대부분 차지

02.
대규모 데이터셋

총 1,170만 건 이상 관측치 확보
다양한 환경조건 포함

03.
희귀 이벤트 예측 문제

모델 성능 평가시
Recall(위험 이벤트 놓침) 중요

위험이벤트 비율이 매우 낮은 희귀 이벤트 문제로, 불균형 데이터를 고려한 분석이 필요

3-1. 연구가설 설정

Hypothesis

교통류, 기상, 도로구조, 시설물 관점에서 총 5개 연구가설 설정
EDA 및 통계검정을 통해 가설 검증 수행

01.

H1. 기상 악화 가설

강수 및 습윤 환경에서는
위험이벤트 발생 가능성이 증가할 것이다.

02.

H2. 속도 변동성 가설

속도 변동성이 큰 구간일수록
위험이벤트 발생 가능성이 증가할 것이다.

03.

H3. 정체·고밀도 교통류 가설

정체 수준이 높고 교통밀도가 증가할수록
위험이벤트 발생 가능성이 증가할 것이다.

04.

H4. 도로선형·굴곡도 가설

굴곡도가 높은 구간에서는
위험이벤트 발생 가능성이 증가할 것이다.

05.

H5. 시설물 인접 가설

IC, JC, TG 등 시설물 인접 구간에서는
위험이벤트 발생 가능성이 증가할 것이다.

06.

H6. 구조물 인접 가설

터널, 교량등 구조물 인접 구간에서는
위험이벤트 발생 가능성이 증가할 것이다.

각 연구가설은 EDA를 통해 1차 검증한 후, 통계적 검정을 통해 최종 검증 진행

3-2. 채택 가설

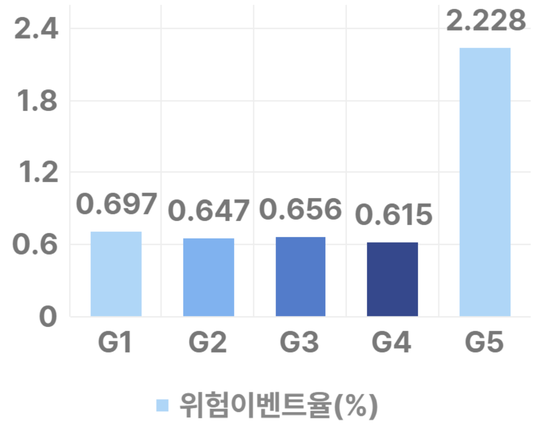
Accepted Hypotheses

채택된 세 가지 가설 모두 교통류의 안정성을 저해하는 공통적인 특성을 가지고 있으며,
위험이벤트 발생과 강한 관계를 보임

01.

H2. 속도 변동성 가설

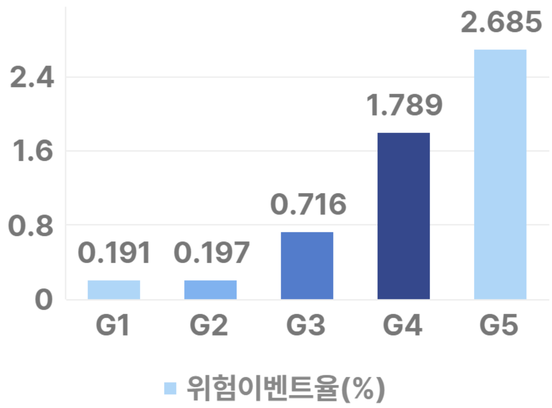
속도 변동성이 매우 큰 구간(G5)에서
위험이벤트 급증



02.

H3. 정체·고밀도 교통류 가설

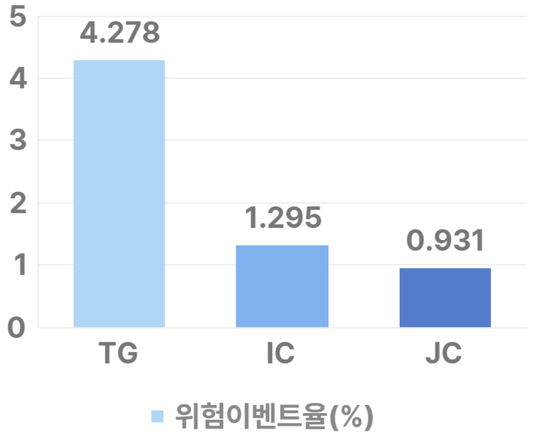
정체 수준 증가에 따라 위험이벤트율 지속 증가,
가장 명확한 패턴 확인



03.

H5. 시설물 인접 가설

TG 인근에서 위험이벤트 집중
IC, JC도 일반구간보다 높음



3-3. 기각 가설

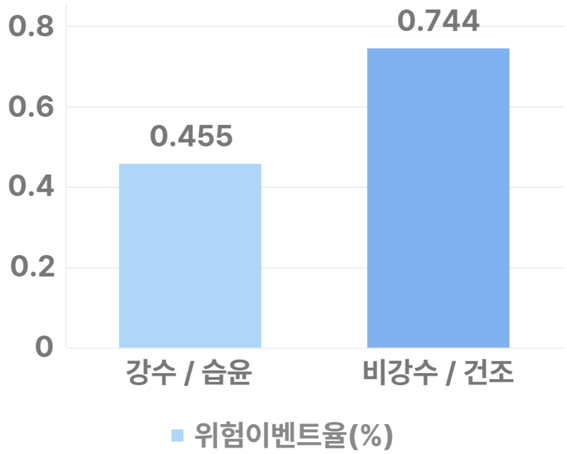
Rejected Hypotheses

예상과 달리 기상조건과 도로선형 변수는 위험이벤트 발생과 뚜렷한 관계를 보이지 않았으며
교량 및 터널 여부 또한 유의한 차이가 확인되지 않음
위험이벤트는 기상이나 구조물보다 교통류 불안정성과 시설물 영향에 더 민감하게 반응하는 것으로 나타남

01.

H1. 기상 악화 가설

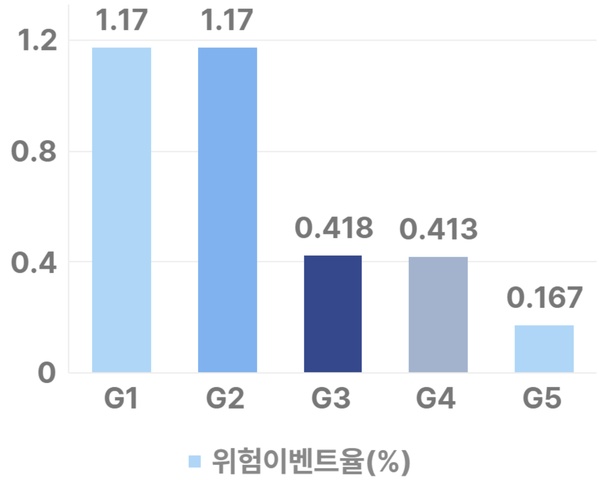
강수 시 위험이벤트율이 더 낮게 나타남
데이터 기준에서는 가설 지지 어려움



02.

H4. 도로선형·굴곡도 가설

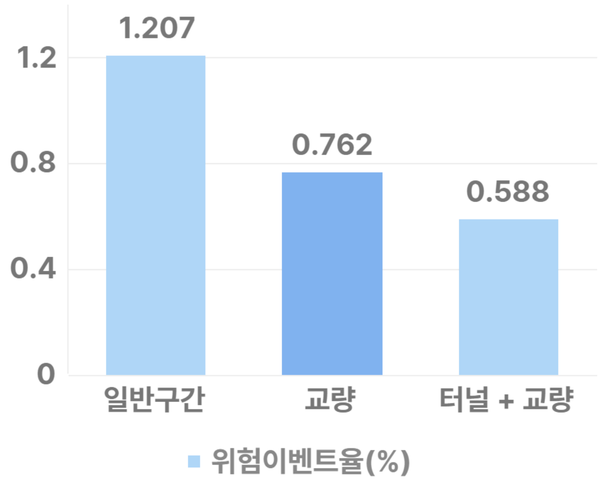
예상과 반대,
굴곡도가 높을수록 위험이벤트율 감소



03.

H6. 구조물 인접 가설

터널, 교량 인근에서는
위험 위벤트율이 높지 않았음



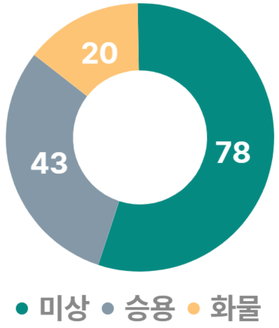
3-4. 보조가설

Supplementary EDA

- 실제 사고 데이터 분석 결과,
  승용·화물 차량 중심의 사고 특성이 확인되었으며
  사고는 특정 시간대와 특정 구간에 집중되는 경향을 보임
- 다만 미상 차종 비율이 높아 차종별 해석에는 한계가 존재

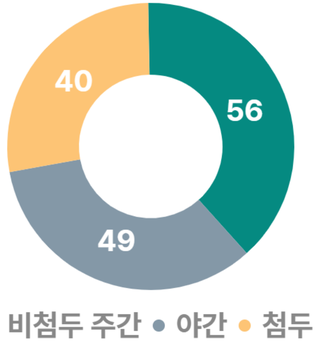
01. 가해차종별 사고 빈도

차종	사고건수
미상	78건
승용	43건
화물	20건



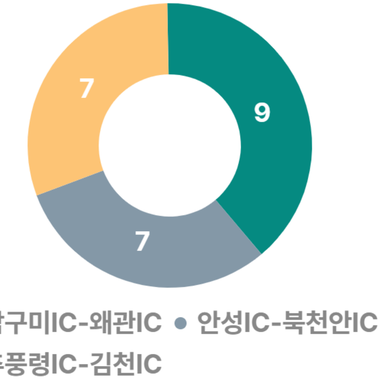
02. 시간대별 사고 분포

시간대	사고건수
비첨두 주간	56건
야간	49건
첨두	40건



03. 사고다발구간 분석

순위	CZ 구간	사고건수
1	남구미IC ~ 왜관IC	9건
2	안성IC ~ 북천안IC	7건
3	추풍령IC ~ 김천IC	7건



실제 사고 역시 특정 시간대와 구간에 집중되는 경향을 보이며
위험이벤트 분석 결과와 유사한 패턴을 확인

3-5. 가설 검정 Hypothesis Testing

EDA를 통해 확인된 주요 결과에 대해 통계적 검정을 수행한 결과,
속도 변동성, 정체 수준, 시설물 인접성이 위험이벤트 발생과 유의한 관계를 보이는 것으로 확인

01.

H2. 속도 변동성 가설

위험이벤트 발생 여부가 이진 변수이므로 **로지스틱 회귀** 적용, 속도 변동성은 위험이벤트 발생확률에 유의한 영향을 미치는 것으로 확인

02.

H3. 정체·고밀도 교통류 가설

정체 수준과 위험이벤트 발생확률의 관계를 분석하기 위해 **로지스틱 회귀**를 적용, 정체 수준 증가에 따라 위험이벤트 발생확률이 증가

03.

H5. 시설물 인접 가설

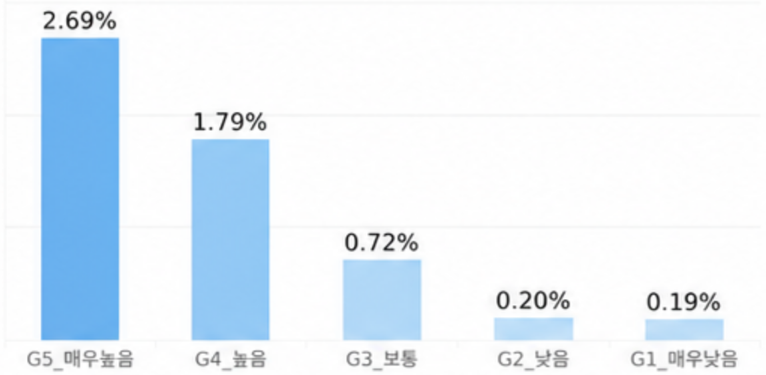
시설물 인접 여부와 위험이벤트 발생 여부 간의 관련성을 확인하기 위해 **카이제곱 검정**을 수행, 두 변수 간 유의한 관계를 확인

가설	검정방법	p-value	결과
H2. 속도 변동성 가설	Logistic Regression	<2e-16	채택
H3. 정체·고밀도 교통류 가설	Logistic Regression	<2e-16	채택
H5. 시설물 인접 가설	Chi-square Test	<2.2e-16	채택

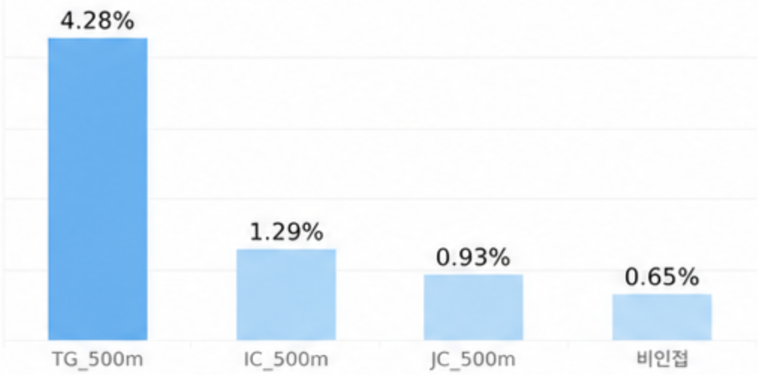
교통사고 위험이벤트 발생요인 분석 대시보드

총 위험이벤트 수	전체 위험이벤트 발생률	최고 위험 시설물	최고 위험 정체수준
86,354번	0.74%	TG_500m / 4.28%	G5_매우높음 / 2.69%

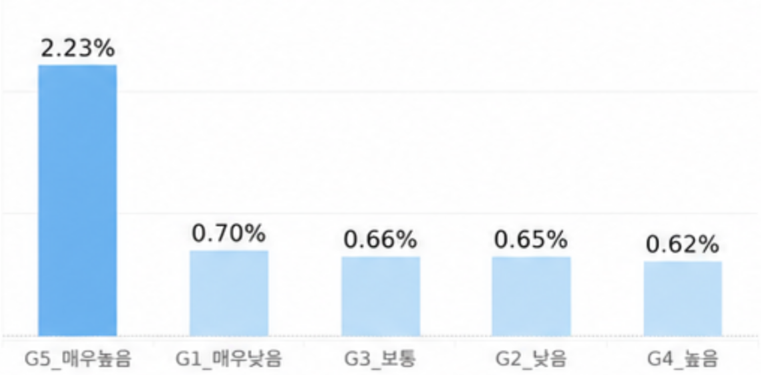
정체 수준별 위험이벤트율



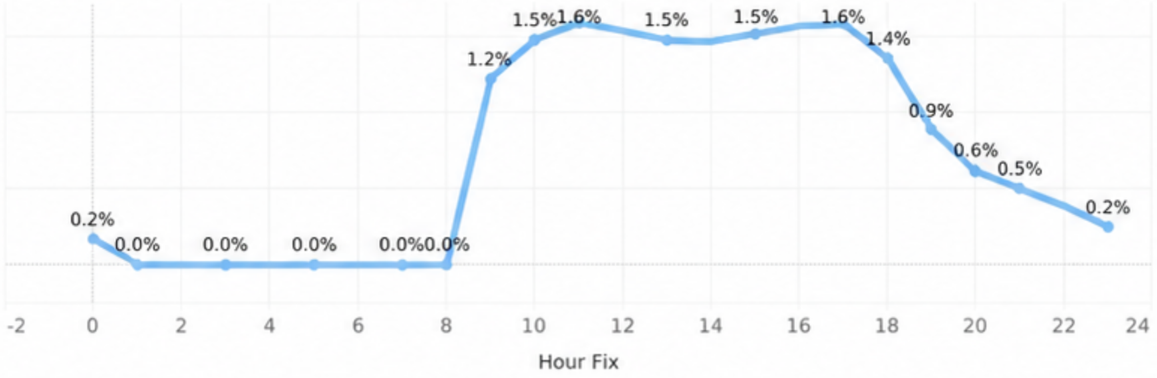
시설물 인접구간 위험이벤트율



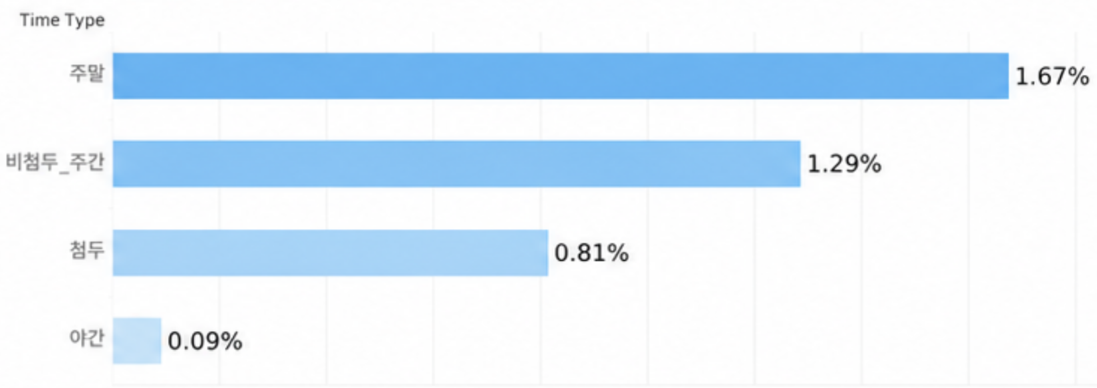
속도변동성별 위험이벤트율



시간대별 위험이벤트율



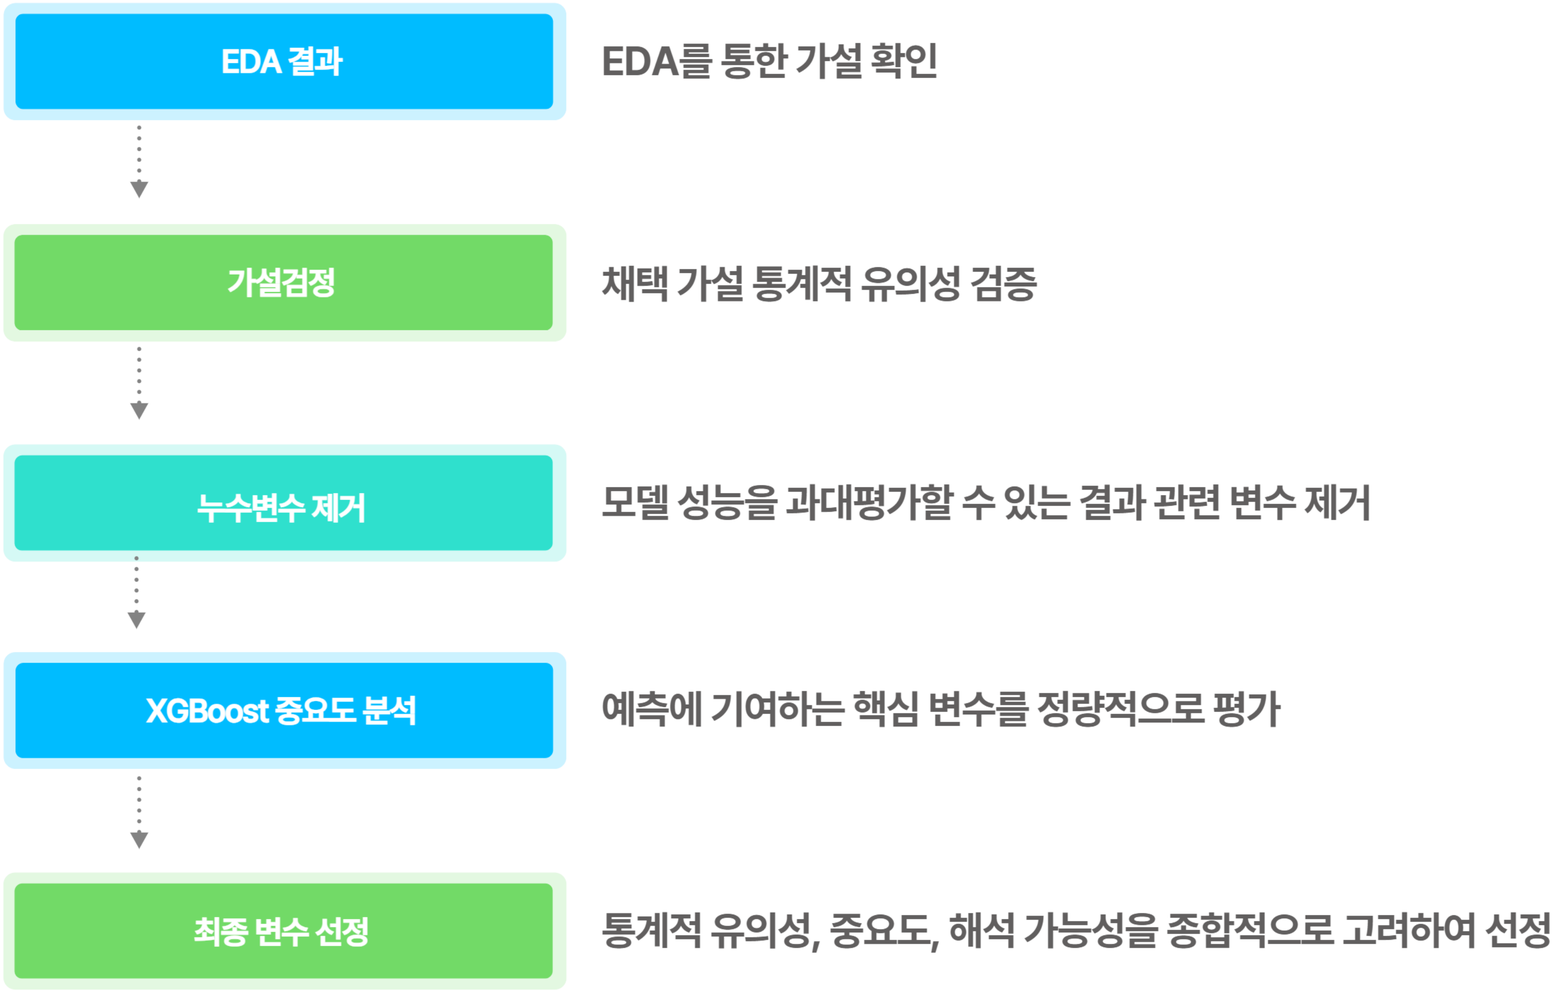
시간유형별 위험이벤트율



4-1. 변수 선정

Feature Selection

- EDA 및 가설검정을 통해 위험이벤트와 유의한 관련성이 확인된 변수들을 후보군으로 선정
- 이후 누수변수를 제거한 뒤 XGBoost 중요도 분석을 수행하여 예측 기여도가 높은 핵심 변수들을 최종 선정



4. 머신러닝 모델 개발

XGBoost 중요도 기준 상위 15개 최종 선별 변수

flow_density
hour
mean_curvature
sum_bearing_change
vol
speed
curve_vol_density
SSD_15
occ_speed_ratio
speed_cv
SSD_5
tunnel_occ
night_flag
facility_flag_500m
ic_near_500m

최종 선별 교통안전지표

flow_density : 교통밀도 반영

occ_speed_ratio : 정체 수준 반영

speed_cv : 속도 변동성 반영

SSD_5 : 단기 공간적 속도차 반영

SSD_15 : 장기 공간적 속도차 반영

4-2. 머신러닝 모델 구축

Model Development

해석력이 높은 모델부터 고성능 앙상블 모델까지 다양한 알고리즘을 비교하여
위험이벤트 예측에 가장 적합한 모델을 선정

01.

Logistic Regression

해석이 용이한 선형 모델
기준선(Baseline Model) 역할
머신러닝 모델 성능 비교를 위한
기준 모델로 활용

02.

Decision Tree

규칙 기반 분류 가능
높은 해석력
변수 간 분기 구조 확인

03.

Random Forest

앙상블 기반
과적합 완화
안정적인 성능 확보

04.

XGBoost

Gradient Boosting 기반
변수 중요도 분석 가능
고성능 예측 및 변수 중요도 분석

05.

LightGBM

대용량 데이터 처리 강점
빠른 학습 속도
불균형 데이터에 효과적이며
높은 예측 성능 기대

평가 지표	목적
Accuracy	전체 분류 정확도
Precision	오탐 최소화
Recall	위험이벤트 탐지
F1-score	정밀도·재현율 균형
AUC	전체 분류 성능

4-3. 모델 성능 비교 및 최종선택

Model Performance & Final Selection

- 모델별 성능 비교 결과, Random Forest는 Accuracy(94.7%), F1-score(86.1%), AUC(97.5%)에서 가장 우수
- LightGBM은 Recall(90.2%)이 가장 높아 위험이벤트를 놓치는 비율 (False Negative)이 가장 낮게 나타남

전체 모델 성능 비교

	model	threshold	Accuracy	Precision	Recall	F1	AUC
1	Logistic	0.5	0.8527511	0.6827737	0.4826881	0.5655556	0.8761570
2	Decision Tree	0.5	0.8804887	0.7857064	0.5474196	0.6452670	0.8937935
3	RandomForest	0.5	0.9472764	0.9063728	0.8190836	0.8605203	0.9753559
4	XGBoost	0.5	0.8943996	0.6797155	0.8853592	0.7690270	0.9578638
5	LightGBM	0.5	0.9214780	0.7521899	0.9015710	0.8201338	0.9710984

Random Forest 혼동행렬

Random Forest Confusion Matrix

		Predicted	
		0	1
Actual	0	99716	4850
	1	10768	15139

전체 성능은 가장 우수하였으나,
일부 위험이벤트를 놓치는 한계가 존재

LightGBM 혼동행렬

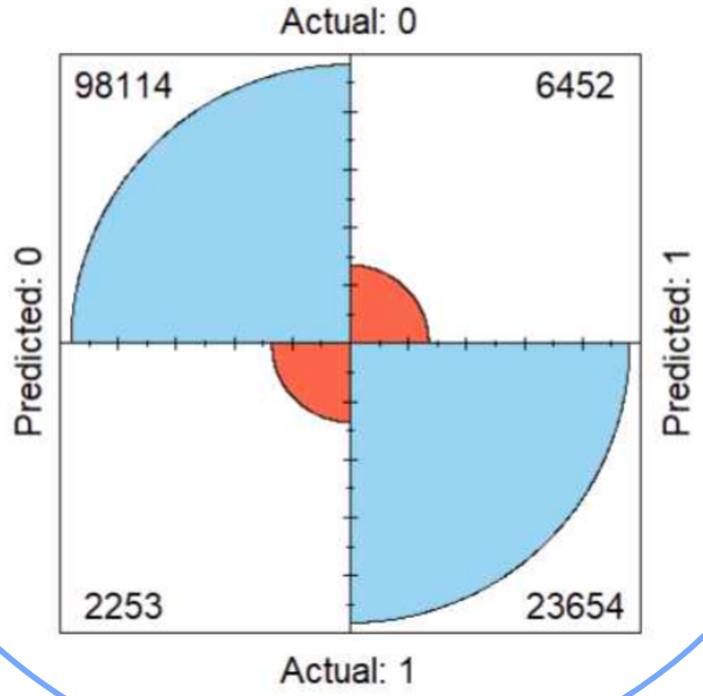
LightGBM Confusion Matrix

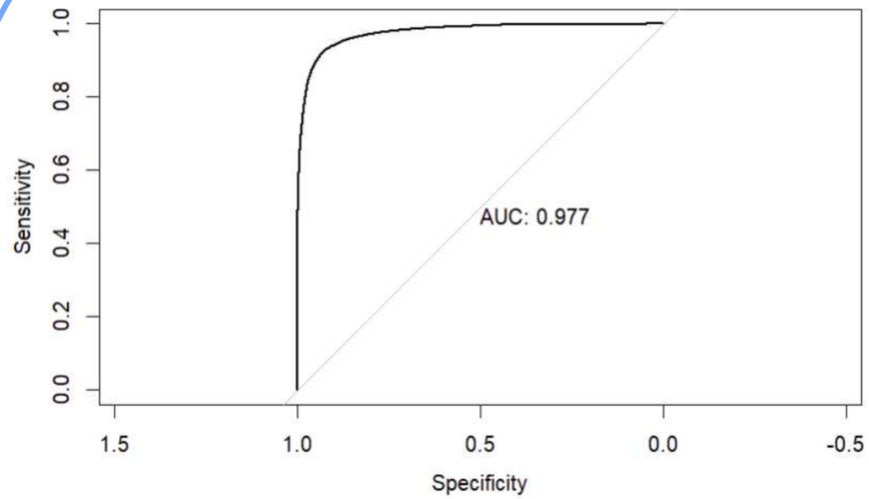
		Predicted	
		0	1
Actual	0	98114	6452
	1	2253	23654

위험이벤트 탐지 성능(Recall)이
가장 우수하여 최종 모델로 선정

LightGBM이 위험이벤트 탐지 성능과 전체 분류 성능 모두에서 가장 우수한 결과를 보여 최종 모델로 선정

LightGBM Confusion Matrix





LigthGBM ROC Curve

4-4. 하이퍼 파라미터 튜닝 Hyperparameter Tuning

하이퍼 파라미터란 모델의 학습 방식과 성능을 결정하는 사전 설정 변수로
5-Fold 교차검증과 Grid Search를 활용하여 모델별 최적 하이퍼파라미터를 탐색하고, 일반화 성능이 가장 우수한 모델을 선정

튜닝 방법

5-Fold Cross Validation 적용
Grid Search 기반 하이퍼파라미터 탐색
평가 지표: Recall, F1-score, AUC
위험이벤트 탐지 목적에 따라 Recall을 우선 고려

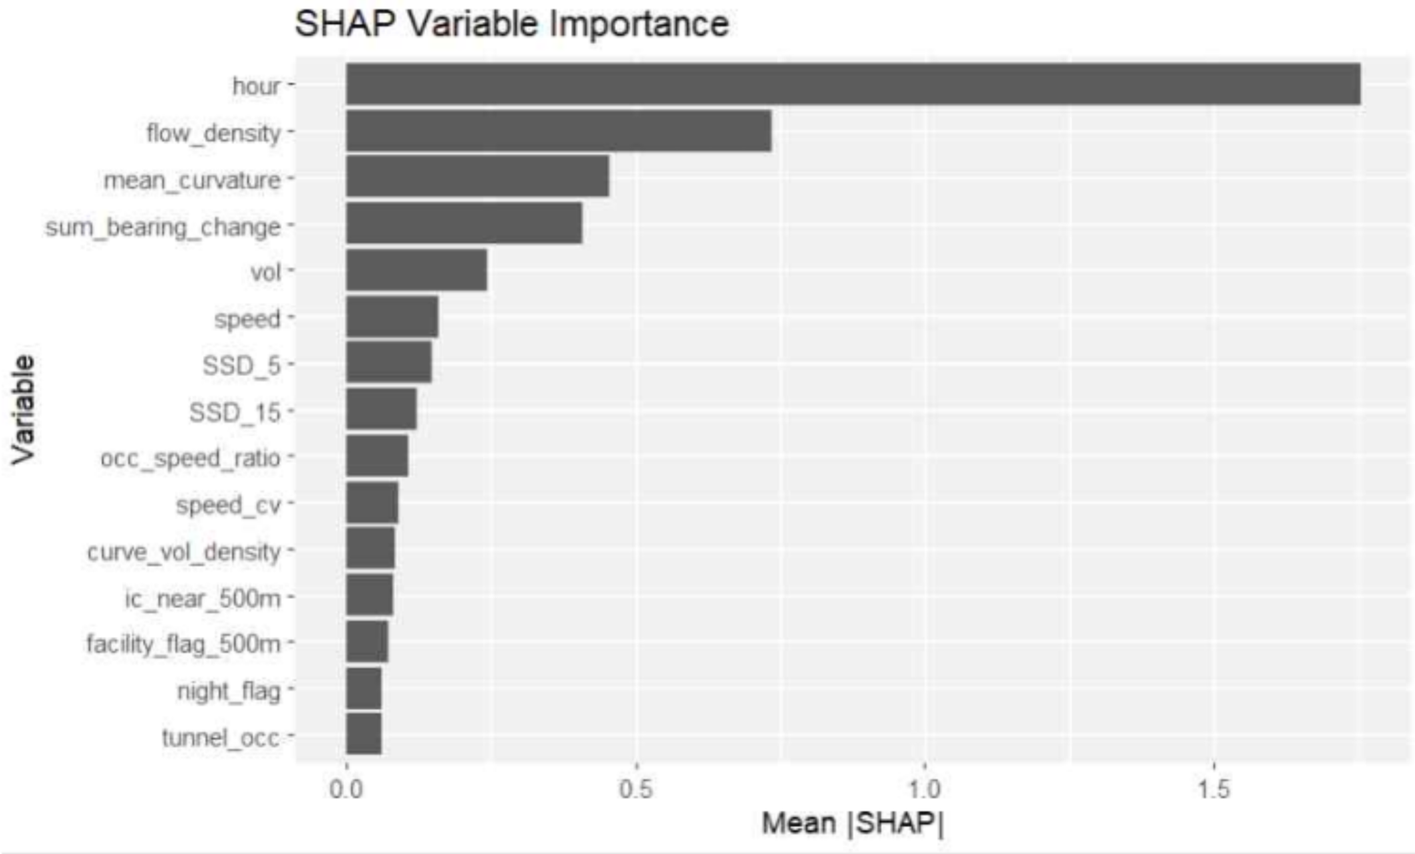
모든 모델은 5-Fold 교차검증 기반으로 최적 하이퍼파라미터를 탐색하여 과적합을 최소화하고 일반화 성능을 향상시킴

Model	Hyperparameter	Description	Search Range
Random Forest	ntree mtry maxnodes	트리 개수 분할 변수 수 최대 노드 수	100 (고정) {3, 4, 5} {20, 40}
LightGBM	num_leaves max_depth learning_rate feature_fraction bagging_fraction	최대 리프 수 최대 깊이 학습률 변수 샘플링 비율 데이터 샘플링 비율	{31, 63} {5, 7} {0.05, 0.03} 0.8 (고정) 0.8 (고정)

4-5. SHAP 분석-중요도

SHAP Analysis

SHAP 분석 결과, 모델은 시간대, 교통밀도, 도로선형 특성을 주요 판단 근거로
활용하여 위험이벤트를 예측하는 것으로 나타났으며 EDA 및 가설검정 결과와 일관된 패턴



중요도 TOP 4

- **Hour**
  - 가장 높은 SHAP 중요도 (1.754)
  - 시간대가 증가할수록 위험예측이 증가하는 경향
  - 특히 주간 및 오후 시간대에서 위험이벤트 발생 가능성이 높게 나타남
- **Flow_Density**
  - 교통밀도가 증가할수록 위험예측이 증가
  - 차량 상호작용 증가로 인해 위험이벤트 발생 가능성이 높아지는 것으로 나타남
- **Mean_Curvature**
  - 높은 SHAP 중요도를 보였으나
  - 곡률이 증가할수록 위험예측은 감소하는 경향
- **Sum_Bearing_Change**
  - 높은 SHAP 중요도를 보였으나
  - 방향 변화량 증가는 위험예측 증가와 직접적인 관련성을 보이지 않음

4-6. SHAP 분석 - 위험예측

SHAP Analysis

- SHAP 분석 결과,
  교통밀도, 정체 수준, 속도 변동성 및 시설물 인접성은
  위험예측 확률을 증가시키는 주요 요인으로 나타남

- 이는 EDA 및 가설검정 결과와도 일치

위험예측 확률 TOP4

- **Flow Density**
  교통밀도 증가 시 위험예측 증가
  교통밀도가 높을수록 차량 간 상충 가능성이 증가

- **Occ Speed Ratio**
  정체 수준 증가 시 위험예측 증가
  점유율 대비 속도 비율이 높을수록 혼잡 심화

- **Speed CV**
  속도 변동성 증가 시 위험예측 증가
  불안정한 교통류 환경에서 급감속 및 상충 발생 가능성 증가
  교통류 불안정성의 핵심 지표

- **Facility Flag 500m**
  시설물 인접 시 위험예측 증가
  가감속 및 차로변경이 빈번하게 발생

5-1. 통합모델 효과 검증

Integrated Model Validation

교통류 중심 분석에서 벗어나 도로환경 및 시설물 정보를 통합함으로써 위험이벤트 예측 성능을 크게 향상시킴

교통류 기반 모델

사용 변수

speed | VOL | OCC | SSD | TSD | TSSD

Recall = 0.812
F1 - score = 0.662
AUC = 0.903
Precision = 0.558
Accuracy = 0.835

+ 도로선형
+ 시설물
+ 시간정보

Recall (+12.4%)
F1-score (+27.6%)
AUC (+8.2%)
Precision (+40.7%)
Accuracy (+11.7%)

사용 변수

교통류 | 도로선형 | 시설물 | 시간정보

Recall = 0.913
F1 - score = 0.844
AUC = 0.977
Precision = 0.786
Accuracy = 0.933

통합 모델

5-2. 연구 기여도

Research Contributions

교통류 중심 연구를 확장하여 통합 데이터 기반 위험예측 체계를 구축하고
시설물 및 공간정보의 효과를 정량적으로 검증

통합 데이터 기반 위험분석 체계 구축

교통류 중심 분석을 확장한 통합 데이터 기반 분석 체계 제안

VDS, 기상, 도로선형, 시설물 데이터를 통합

11,704,666건 규모 데이터셋 구축

총 36개의 신규 변수 생성

시설물 및 공간정보 영향 정량화

기존 연구에서 상대적으로 부족했던 시설물 영향 정량화

TG 인근 위험이벤트율 4.278%

IC 인접 구간 위험도 증가 확인

시설물 인접성의 통계적 유의성 검증

위험예측 모델 및 해석 가능성 제시

위험이벤트를 사전에 탐지할 수 있는 예측체계 제시

LightGBM 기반 예측모델 구축

AUC 0.977 달성

SHAP 분석을 통한 위험요인 해석

통합 데이터 기반 위험예측 체계를 구축하고 시설물 및 공간정보의 효과를 정량적으로 검증

5-3. 연구결론

Research conclusion

시설물과 도로환경 정보를 추가할 경우 예측 성능이 크게 향상

위험이벤트는 정체·고밀도 교통류와 속도 변동성, 시설물 영향이 결합될 때 증가하며, 통합 데이터 기반 접근이 이를 가장 효과적으로 설명하는 것으로 확인

- 정체 수준 0.191% → 2.685%
- 시설물 TG 4.278%
- 속도 변동성 G5 2.228%
- 통합모델 성능 최적화

정체 수준은 가장 강력한 위험요인으로 확인

정체 수준이 증가할수록 위험이벤트 발생률이 지속적으로 증가하였으며, EDA와 SHAP 분석 모두에서 핵심 변수로 나타남

시설물 인접 구간에서 위험이벤트 발생 가능성이 높게 나타남

특히 TG 인근 구간의 위험이벤트율이 가장 높게 나타났으며,시설물 인접성은 통계적으로 유의한 위험요인으로 확인됨

속도 변동성은 위험상황을 설명하는 핵심 교통류 변수로 확인

Speed CV가 증가할수록 위험이벤트 발생 가능성이 증가, 가설검정 및 SHAP 분석 결과와도 일치

통합 데이터 활용 시 위험예측 성능이 크게 향상

교통류 변수만 사용한 모델 대비 통합모델(Recall, F1-score, AUC, Precison, Accuracy)이 우수한 성능을 보임

5-4. 정책적 시사점

Implications and Applications

단순한 위험요인 분석에 그치지 않고, 실시간 위험예측과 고속도로 운영 정책에 활용 가능한 실무적 시사점을 제시



TG·IC 인근 집중 관리

TG 및 IC 인접 구간에서 위험이벤트 발생 가능성이 높음

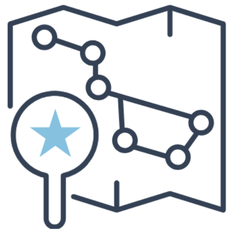
→ 위험도가 높은 시설물 인접 구간을 우선 관리대상으로 선정 필요



위험구간 실시간 모니터링

교통밀도(flow_density), 정체 수(occ_speed_ratio), 속도 변동성(speed_cv)이 주요 위험요인으로 확인

→ 실시간 교통류 지표를 활용한 위험 모니터링 체계 구축



ITS 기반 위험예측 서비스

LightGBM 기반 모델은 높은 위험탐지 성능을 보임

→ ITS 및 교통관제시스템과 연계하여 사전 위험경고 서비스에 활용 가능



사고 대응에서 사고 예방으로

위험이벤트를 사전에 탐지할 수 있는 가능성을 확인

→ 사고 발생 후 대응이 아닌 사고 발생 전 예방 중심의 교통안전 정책 수립

6-1. 한계점

Limitation

교통류 중심 연구를 확장하여 통합 데이터 기반 위험예측 체계를 구축하고
시설물 및 공간정보의 효과를 정량적으로 검증

사고 중심 모델 구축

급감속 변수를 입력변수로 활용하여
실제 사고 발생만을 예측하는
모델 구축이 가능할 것으로 기대

전국 고속도로 확대

경부고속도로 외 다양한 노선을
포함하여 고속도로별 위험특성을
비교하고 일반화 가능성을 검증

장기 데이터 활용

1년 이상 장기 데이터를 활용하여
계절별·연도별 위험특성 변화를
분석할 필요

임계값 최적화

Precision과 Recall의 균형을
고려한 최적 Threshold를 탐색하여
위험탐지 성능을 더욱 향상시킬 필요

6-2. 참고문헌

References

1. 정은비, 오철 (2011), 속도를 이용한 고속도로 구간 사고율 예측 모형

2. 성제민, 윤병조 (2024), XGBoost를 활용한 첨두·비첨두시간 사고 심각도 영향요인 분석

3. 최강록, 박훈태, 맹기영 (2025), 도로 기하구조의 연속성이 교통사고 심각도에 미치는 영향

4. Romanowska & Budzyński (2022), Investigating the Impact of Weather Conditions and Time of Day on Traffic Flow Characteristics

5. Gorzelanczyk (2021), Impact of Weather Conditions and Road Type on Traffic Safety

6. Li et al. (2023), Identifying High-Risk Roadways Using Crowdsourced Speed Variation Features from Big Mobility Data

7. Yang et al. (2022), Examining Causal Factors of Traffic Instability Using Traffic Flow and Driving Behavior Data

8. Jung & Qin (2021), A Data-Driven Approach to Strengthening Policies to Prevent Freeway Tunnel Strikes by Motor Vehicles

Thank you for Watching

이상 발표를 마치겠습니다

교통물류빅데이터마이닝

6조

박선우

정채환

최윤호

임선영